

금융 분석과 모델링

모듈 - 1

1. 가
- 2.
3. -

강사: 장순용 박사

순서

1. 금융 분석과 모델링.

1.1. 시계열 모델링 개요.

1.2. 이동평균.

1.3. 지수평활화 모형.

부록 1. 시계열 모형의 활용.

부록 2. 변동성 모델링.

부록 3. 변동성 예측.

시계열이란?

- 시간 순서대로 정렬된 수치 데이터.
- 관측 값이 시간에 따라서 변한다.
- 시간 단위를 전제한다. ⇒ 1분, 1초, 하루, 한달, 등.
- 표기방법: x_1, x_2, x_3, \dots or X_t .
1, 2, 3 () - x가 , 가, 가~
- 많은 경우 시계열의 현재는 과거와 “연결”된다. 즉, 자기상관계수 $\neq 0$.

시계열의 사례:


- 삼성전자, 애플, 구글과 같은 회사의 일일 주식가격.
- 한 시간 단위로 교차로를 지나는 자동차 대수.
- 달러화 대 원화 일일 환율.

시계열 모델링 개요

시계열의 사례:

시간
↑


SAMSUNG ELECTRONICS	
Date	Price
2017-02-02	1968000
2017-02-01	1956000
2017-01-31	1973000
2017-01-30	1995000
2017-01-27	1995000
2017-01-26	1995000
2017-01-25	1970000
2017-01-24	1908000
2017-01-23	1903000
2017-01-20	1860000



시계열 모델링 개요

비정상 시계열 (Non Stationary Time Series):

- 시간이 지나면 확률적 특성이 유지되지 않는다.
- 평균, 분산, 자기상관계수 등이 시간이 지남에 따라서 변할 수 있다.
- 시계열에 추세성 요소 (trend)가 있다. 예). 랜덤워크.



가
가

가

가


39

89

시계열 모델링 개요

정상 시계열 (Stationary Time Series):

- 시간이 지나도 모든 확률적 특성이 그대로 유지되는 시계열이다.
- 이 조건은 너무나 엄격하기 때문에 “약정상성”으로 완화한다.



약정상 시계열 (Weak Stationary Time Series):

- 평균이 일정하게 유지됨: $\bar{x} = E[x_t]$.
- 분산이 일정하게 유지됨: $s^2 = Var(x_t) = Cov(x_t, x_t) = E[(x_t - \bar{x})(x_t - \bar{x})]$.
- 시점 i 와 시점 j 사이의 자기상관계수가 $Corr(x_i, x_j) = \rho(|i - j|)$ 와 같은 함수관계임.
즉, 시점 사이의 거리에 의해서 정해짐.

시계열 모델링 개요

자기공분산 (Auto-Covariance Function):

→ 자기공분산 수식: $\gamma(\ell) = \text{Cov}(x_t, x_{t-\ell}) = E[(x_t - \bar{x})(x_{t-\ell} - \bar{x})]$.

→ $\gamma(\ell) = \text{Cov}(x_{t-1}, x_{t-1-\ell}) = \text{Cov}(x_{t-2}, x_{t-2-\ell}) = \dots$


→ 시계열의 전체적 분산과 연관된다: $s^2 = \gamma(0)$.

자기상관계수 (Auto-Correlation Function, ACF):

- 자기공분산 $\gamma(\ell)$ 를 사용해서 정의할 수 있다: $\rho(\ell) = \gamma(\ell) / \gamma(0)$.
- 모든 시계열에서 시점 사이의 차이가 0이면 $\rho(0) = 1$ 과 같다.


자기상관계수 (Auto-Correlation Function, ACF):

예). 강하지 않은 자기상관성.




자기상관계수 (Auto-Correlation Function, ACF):

예). 강하지 않은 자기상관성.



자기상관계수 (Auto-Correlation Function, ACF):


예). 상대적으로 강한 자기상관성.



가 - >

자기상관계수 (Auto-Correlation Function, ACF):

예). 상대적으로 강한 자기상관성.



1. 금융 분석과 모델링.

1.1. 시계열 모델링 개요.

1.2. 이동평균.

1.3. 지수평활화 모형.

부록 1. 시계열 모형의 활용.

부록 2. 변동성 모델링.

부록 3. 변동성 예측.

이동평균

이동평균 개요:

- 이동평균은 시계열의 부분집합으로 평균을 구하여 평활화 효과를 얻는 방법이다.
- 평활화의 목적은 노이즈와 같이 짧은 주기의 특징을 걸러내고 긴 주기의 추세를 밝혀 내는 것.

가

가

이동평균

이동평균의 유형:

,가

- 단순 이동평균은 다음과 같이 계산한다. N =moving window의 길이.

$$\text{단순 이동평균}_t = \frac{1}{N} \sum_{i=0}^{N-1} x_{t-i}$$

- 지수 이동평균은 다음과 같이 구한다. 0과 1사이의 α 파라미터로 평활화 정도를 조정할 수 있다.

$$\text{지수 이동평균}_t = \frac{\sum_{i=0}^{N-1} (1-\alpha)^i x_{t-i}}{\sum_{j=0}^{N-1} (1-\alpha)^j}$$

5 , 10
5 , 10

→ α 파라미터가 0에 가까울 수록 단순이동평균에 수렴한다.


→ α 파라미터가 1에 가까울 수록 원 시계열에 수렴한다.

가

-가

이동평균

이동평균의 유형:



가

이동평균

이동평균의 유형:

- Running 이동평균은 지수 이동평균의 응용이다.

$\alpha = \frac{1}{N+1}$ 와 같은 지수 이동평균이다.

- 가중 이동평균을 계산하기 위해서는 두개의 시계열이 필요하다. x_t, x_{t-1}, \dots 과 무게를 계산하기 위한 V_t, V_{t-1}, \dots .

$$\text{가중 이동평균}_t = \frac{\sum_{i=0}^N w_{t-i} x_{t-i}}{\sum_{j=0}^N w_{t-j}} \quad \leftarrow \left\{ w_{t-i} = \frac{V_{t-i}}{\sum_{j=0}^N V_{t-j}} \right.$$

가


가

가

가

이동평균

이동평균의 유형:



가중이동평균으로 구한 주식가격의 VWAP (Volume Weighted Average Price)

가

1. 금융 분석과 모델링.

1.1. 시계열 모델링 개요.

1.2. 이동평균.

1.3. 지수평활화 모형.

부록 1. 시계열 모형의 활용.

부록 2. 변동성 모델링.

부록 3. 변동성 예측.

지수평활화 모형:

- 크게는 다음 두 가지 유형의 지수평활화 모형이 있다.

→ 가법모형 (Additive Model):

시계열 변동을 요인의 합으로 설명한다.

진폭이 일정할 때 적합하다.

→ 승법모형 (Multiplicative Model):

시계열 변동을 요인의 곱으로 설명한다.

진폭이 점점 증가/감소 할 때 적합하다.

지수평활화 가법모형 (Additive Model):

- 시계열 X_t 가 있을 때, 다음과 같은 관계를 가정한다:

$$X_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$$

- >

지수평활화 모형

지수평활화 가법모형 (Additive Model):

- 시계열 x_t 가 있을 때, 다음과 같은 관계를 가정한다:

$$X_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$$

전 스텝의 “level”.

가

지수평활화 모형

지수평활화 가법모형 (Additive Model):

- 시계열 X_t 가 있을 때, 다음과 같은 관계를 가정한다:

$$X_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$$

전 스텝의 “trend”.

지수평활화 모형

지수평활화 가법모형 (Additive Model):

- 시계열 X_t 가 있을 때, 다음과 같은 관계를 가정한다:

$$X_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$$

“불확실성”

$$\text{평균}(\varepsilon_t)=0$$

$$\text{표준편차}(\varepsilon_t)=\sigma_\varepsilon$$

지수평활화 가법모형 (Additive Model):

- 시계열 X_t 가 있을 때, 다음과 같은 관계를 가정한다:

$$X_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$$

- “level”과 “trend” 사이에는 다음과 같은 관계를 가정한다:

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$$

$$b_t = b_{t-1} + \beta \varepsilon_t$$

가 (가)

가법모형의 예측:

- 스텝 t 까지 데이터가 있고 미래 h 스텝을 예측하고자 한다: $\hat{X}_{t+h|t}$
- 기대값으로 미래 예측을 하고자 한다. 이때 미래 ε_t 의 기대값은 0이다.

⇒ 미래의 **평균 경로**를 구하고자 한다.

- 다음과 같은 수식으로 구할 수 있다.


$$\hat{X}_{t+h|t} = \ell_t + hb_t$$

h

지수평활화 모형

가법모형의 예측:

- 미래의 평균 경로 예측은 다음과 같은 직선이다.



예측과 신뢰구간:


()

- 평균 경로 뿐만이 아니라 신뢰구간을 계산하고자 한다.
 - 평균 경로 뿐만이 아니라 모든 가능한 경로를 고려해 본다.
 - 불확실성 ε_t 의 효과를 미래 경로 예측에 포함시킨다.
 - 시뮬레이션 방법을 적용한다.

지수평활화 모형

예측과 신뢰구간:

- 시뮬레이션 방법으로 구한 파란색 경로는 불확실성을 포함한다.
가



지수평활화 모형

예측과 신뢰구간:


- 경로의 확률 분포를 사용해서 신뢰구간을 구한다.

->

가

(

)



계절성 (주기성):

- 일정 주기로 반복되는 패턴이 있다면 모형을 확장하여 추가할 수 있다.

⇒ Holt-Winters 승법모형: 계절성을 나타내는 s_t 를 승법으로 추가 (m =주기).

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha \frac{\varepsilon_t}{s_{t-m}}$$

$$b_t = b_{t-1} + \beta \frac{\varepsilon_t}{s_{t-m}}$$

$$s_t = s_{t-m} + \gamma \frac{\varepsilon_t}{\ell_{t-1} + b_{t-1}}$$

가

계절성 (주기성):

- 일정 주기로 반복되는 패턴이 있다면 모형을 확장하여 추가할 수 있다.
⇒ Holt-Winters 승법모형에 의한 h 스텝 미래 예측은 다음과 같다.


$$\hat{X}_{t+h|t} = (\ell_t + hb_t)s_{t-m+h_m^+}$$

여기에서 $h_m^+ = \text{mod}(h - 1, m) + 1$ 와 같다.

지수평활화 모형

계절성 (주기성):

- Holt-Winters 승법모형을 활용한 1년 단위 (12개월) 주기성 포함 예측의 예.



실습 #0301

→ 사용: **ex_0301.ipynb** ←

실습 #0302

→ 사용: **ex_0302.ipynb** ←

순서

1. 금융 분석과 모델링.

1.1. 시계열 모델링 개요.

1.2. 이동평균.

1.3. 지수평활화 모형.

부록 1. 시계열 모형의 활용.

부록 2. 변동성 모델링.

부록 3. 변동성 예측.

AR 시계열 모형 (Auto-Regressive Model):

- AR(1) 모형:

$$x_t = \phi_0 + \phi_1 x_{t-1} + \varepsilon_t$$

- 현재의 값 x_t 가 1스텝 이전의 값 x_{t-1} 와 연관된다.
- 불확실 요소 ε_t 를 “impact” or “innovation” 이라고 부른다.
- ε_t 는 정규확률분포를 따른다는 가정을 한다: $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$.
- $|\phi_1| < 1$ 와 같으면 정상성이 유지된다.
- ϕ_0 는 독립 parameter가 아니다: $\phi_0 = \bar{x}(1 - \phi_1)$.

AR 시계열 모형 (Auto-Regressive Model):

- AR(p) 모형:

$$x_t = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \cdots + \phi_p x_{t-p} + \varepsilon_t$$

→ 현재의 값 x_t 가 p 스텝 이전의 값 x_{t-p} 까지와 연관된다.

→ 정상성을 논하려면 특성근 (characteristic root)을 구해야 한다 → later.

→ ϕ_0 는 독립 parameter가 아니다: $\phi_0 = \bar{x}(1 - \phi_1 - \phi_2 - \cdots - \phi_p)$.

MA 시계열 모형 (Moving Average Model):

- MA(q) 모형:

$$x_t = \varepsilon_t + \bar{x} + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

→ 현재의 값 x_t 가 q 스텝 이전의 impact ε_{t-q} 까지와 연관된다.

→ θ_i 가 모두 유한수(finite number)이면 MA 시계열 모형은 정상시계열에 해당한다.

→ “Square sumable”: $\sum_{i=0}^q \theta_i^2 < \infty$

ARMA 시계열 모형 (Auto-Regressive Moving Average Model):

- ARMA(p,q) 모형:

$$x_t = \varepsilon_t + \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \cdots + \phi_p x_{t-p} + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

→ AR모형과 MA모형의 결합이다.

→ 정상성을 논하려면 AR의 모수 ϕ_i 에 해당하는 특성근을 구해야 한다 → later.

→ ϕ_0 는 독립 parameter가 아니다: $\phi_0 = \bar{x}(1 - \phi_1 - \phi_2 - \cdots - \phi_p)$

→ $\text{ARMA}(p,0) = \text{AR}(p)$ 이며 $\text{ARMA}(0,q) = \text{MA}(q)$ 이다.

ARIMA 시계열 모형 (Auto-Regressive **Integrated** Moving Average Model):

- 차분 연산자 D :

$$Dx_t$$

$$x_t - x_{t-1}$$

$$D^2x_t$$

$$x_t - 2x_{t-1} + x_{t-2}$$

$$D^3x_t$$

$$x_t - 3x_{t-1} + 3x_{t-2} - x_{t-3}$$

$$\vdots$$

$$\vdots$$

ARIMA 시계열 모형 (Auto-Regressive **Integrated** Moving Average Model):


- 만약에 차분 연산자를 d 회 적용하여 정상화 할 수 있는 비정상 시계열이 있다면, ARIMA(p , **d**, q)로 모델링 할 수 있다.
- 그런데, 만약에 시계열이 등분산성 조건을 만족하지 않는다면 이것은 수학적 **변환**을 통해서 정상성을 확보해야 되는 경우이다.

시계열 모형의 선별:


- AR(p) 모형의 길이는 PACF를 사용하여 선별한다.
 - PACF는 ACF와도 유사하게 현시점과 과거 시점 사이의 상관성을 의미한다.
 - PACF는 중간 시점의 기여를 제외한 ACF라고 해석할 수 있다.
- MA(q) 모형의 길이는 ACF를 사용하여 선별한다.
 - White noise의 표준오차는 $\sigma_{wn} = \frac{1}{\sqrt{n}}$. 그러므로 95% 신뢰구간은 다음과 같다:
 $[-1.96 \times \sigma_{wn}, +1.96 \times \sigma_{wn}]$
- 위 신뢰구간의 바깥에 있는 ACF 또는 PACF가 모형의 길이를 정한다. ⇒ **절단점** 확인!

시계열 모형의 활용

시계열 모형의 선별:




시계열 모형의 선별: 다음 분석 그래프에 적절한 시계열 모형은?




시계열 모형의 활용

시계열 모형의 선별: 다음 분석 그래프에 적절한 시계열 모형은?



시계열 모형의 활용

시계열 모형의 선별: 다음 분석 그래프에 적절한 시계열 모형은?



순서

1. 금융 분석과 모델링.

1.1. 시계열 모델링 개요.

1.2. 이동평균.

1.3. 지수평활화 모형.

부록 1. 시계열 모형의 활용.

부록 2. 변동성 모델링.

부록 3. 변동성 예측.


변동성 모델링의 필요성:

- 변동성은 시계열의 표준편차로 나타낸다.
 - 지금까지는 시계열이 **약정상** 조건을 충족하고 분산 (또는 표준편차)가 일정하다는 가정을 하였다.
- ⇒ 변동성은 고정적이라는 가정과 같다.
- ⇒ 정교한 모델링이 필요 없는 상황을 전제하였다.

변동성 모델링의 필요성:

- 하지만, 실제 상황에서는 변동성이 고정적이지 않을 수도 있다.
 - ⇒ 변동성도 전/후 사이에 일종의 상관성이 있다는 것을 알 수 있다.

"volatility clustering"



- ⇒ 옵션 파생상품에서는 변동성이 자산의 가격만큼 중요할 수 있다.
- ⇒ 그러므로 변동성의 정교한 모델링과 예측 방법이 필요하다.

변동성 모델링 개요:

- 지금까지는 impact가 $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ 와 같이 고정적인 σ_ε^2 에 의해서 생성됨을 전제하였다.
- 이제는 impact가 시간에 따라서 변하는 σ_t^2 에 의해서 생성된다는 전제를한다 $\Rightarrow \varepsilon_t \sim N(0, \sigma_t^2)$.

→ 그리고 σ_t^2 의 시계열을 모형화 해본다!

ARCH 모형:

- ARCH(p)모형은 다음을 전제한다.

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2$$

→ ARCH(p)모형에는 $p + 1$ 개의 모수(parameters) α_i 가 있다.

→ 다음과 같은 제약조건이 적용된다.

$$\alpha_0 > 0, \alpha_i \geq 0, \sum_{i=1}^p \alpha_i < 1$$

ARCH 모형:

- ARCH(p)모형은 다음을 전제한다.

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2$$

→ ε_t^2 의 unconditional mean σ^2 은 먼 미래의 σ_t^2 예측과 같다.

$$E[\varepsilon_t^2] = \sigma^2 = \frac{\alpha_0}{1 - (\sum_{i=1}^p \alpha_i)}$$

→ $\alpha_0 = \sigma^2 [1 - (\sum_{i=1}^p \alpha_i)]$ 와 같으니까 독립 모수의 갯수는 p 이다.

GARCH 모형:

- GARCH(p, q)모형은 다음을 전제한다.

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

→ GARCH(p, q)모형에는 $p + 1$ 개의 α_i 와 q 개의 β_i 가 있다.

→ 다음과 같은 제약조건이 적용된다.

$$\alpha_0 > 0, \alpha_i \geq 0, \beta_i \geq 0, \sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j < 1$$

GARCH 모형:

- GARCH(p, q)모형은 다음을 전제한다.

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

→ GARCH($p, 0$)모형은 ARCH(p)모형과 같다.

GARCH 모형:

- GARCH(p, q) 모형은 다음을 전제한다.

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

→ ε_t^2 의 unconditional mean σ^2 은 먼 미래의 σ_t^2 예측과 같다.

$$E[\varepsilon_t^2] = \sigma^2 = \frac{\alpha_0}{1 - (\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j)}$$

< 1

→ $\alpha_0 = \sigma^2 \left[1 - \left(\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j \right) \right]$ 와 같으니까 독립 변수의 갯수는 $p+q$ 이다.

1. 금융 분석과 모델링.

1.1. 시계열 모델링 개요.

1.2. 이동평균.

1.3. 지수평활화 모형.

부록 1. 시계열 모형의 활용.

부록 2. 변동성 모델링.

부록 3. 변동성 예측.

GARCH 모형의 예측:

- 현재의 시간 스텝을 t 라고 할때, 스텝 $t + 1$ 에 대한 예측값은 $\hat{\sigma}_{t+1}^2$ 과 같이 hat 액센트로 표기하기로 한다.
- I 가 과거 데이터(정보)를 의미할 때 예측값은 다음 조건부 기대값으로 구할 수 있다.

$$\hat{\sigma}_{t+1}^2 = E[\sigma_{t+1}^2 | I]$$

GARCH 모형의 예측:

- 그런데, 과거와 현재 시점의 조건부 기대값은 다음과 같다.

$$E[\sigma_t^2|I] = \sigma_t^2 \text{ (현재의 값 그대로)}$$

$$E[\sigma_{t-1}^2|I] = \sigma_{t-1}^2 \text{ (과거의 값 그대로)}$$

$$E[\varepsilon_t^2|I] = \varepsilon_t^2 \text{ (현실화 된 값 그대로)}$$

$$E[\varepsilon_{t-1}^2|I] = \varepsilon_{t-1}^2 \text{ (현실화 된 값 그대로)}$$

GARCH 모형의 예측:

- GARCH 모형에 의하면 스텝 $t + 1$ 에서는 다음 관계가 성립된다.

$$\begin{aligned}\sigma_{t+1}^2 = & \alpha_0 + \alpha_1 \varepsilon_t^2 + \alpha_2 \varepsilon_{t-1}^2 + \alpha_3 \varepsilon_{t-2}^2 + \cdots + \alpha_p \varepsilon_{t-p+1}^2 \\ & + \beta_1 \sigma_t^2 + \beta_2 \sigma_{t-1}^2 + \beta_3 \sigma_{t-2}^2 + \cdots + \beta_q \sigma_{t-q+1}^2\end{aligned}$$

- 등호 양편의 조건부 기대값을 구하면 $t + 1$ 스텝의 예측은 다음과 같다.

$$\begin{aligned}\hat{\sigma}_{t+1}^2 = & \alpha_0 + \alpha_1 \varepsilon_t^2 + \alpha_2 \varepsilon_{t-1}^2 + \alpha_3 \varepsilon_{t-2}^2 + \cdots + \alpha_p \varepsilon_{t-p+1}^2 \\ & + \beta_1 \sigma_t^2 + \beta_2 \sigma_{t-1}^2 + \beta_3 \sigma_{t-2}^2 + \cdots + \beta_q \sigma_{t-q+1}^2\end{aligned}$$

GARCH 모형의 예측:

- 이제는 스텝 $t + 2$ 에 대한 예측을 하고자 하는데 impact의 기대값이 다음과 같음에 유의한다.

$$\hat{\varepsilon}_{t+1} = E[\varepsilon_{t+1}|I] = 0$$

$$\hat{\varepsilon}_{t+1}^2 = E[\varepsilon_{t+1}^2|I] = \hat{\sigma}_{t+1}^2$$

- 그러므로 스텝 $t + 2$ 에서의 예측은 다음과 같다.

$$\begin{aligned}\hat{\sigma}_{t+2}^2 &= \alpha_0 + \alpha_1 \hat{\sigma}_{t+1}^2 + \alpha_2 \varepsilon_t^2 + \alpha_3 \varepsilon_{t-1}^2 + \cdots + \alpha_p \varepsilon_{t-p+2}^2 \\ &\quad + \beta_1 \hat{\sigma}_{t+1}^2 + \beta_2 \sigma_t^2 + \beta_3 \sigma_{t-1}^2 + \cdots + \beta_q \sigma_{t-q+2}^2\end{aligned}$$

GARCH 모형의 예측:

- 또 한 스텝 더 나가서, $t + 3$ 에서의 예측은 다음과 같다.

$$\begin{aligned}\hat{\sigma}_{t+3}^2 &= \alpha_0 + \alpha_1 \hat{\sigma}_{t+2}^2 + \alpha_2 \hat{\sigma}_{t+1}^2 + \alpha_3 \varepsilon_t^2 + \cdots + \alpha_p \varepsilon_{t-p+3}^2 \\ &\quad + \beta_1 \hat{\sigma}_{t+2}^2 + \beta_2 \hat{\sigma}_{t+1}^2 + \beta_3 \sigma_t^2 + \cdots + \beta_q \sigma_{t-q+3}^2\end{aligned}$$

- 마지막으로, 먼 미래 ($h \rightarrow \infty$)의 예측은 unconditional mean으로의 수렴을 의미한다.

$$\hat{\sigma}_{t+h}^2 \rightarrow E[\varepsilon_t^2] = \sigma^2 = \frac{\alpha_0}{1 - (\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j)}$$

GARCH 모형의 예측:

- 이제는, GARCH(1,1) 모형의 예측에 대해서 자세히 알아본다.
- GARCH(1,1)모형은 다음과 같다.

$$\sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2$$

- 그리고, $\sigma^2 = \alpha_0 / (1 - \alpha_1 - \beta_1)$ 와 같은 unconditional mean의 조건을 대입해서 정리하면 다음과 같다.

$$\sigma_t^2 - \sigma^2 = \alpha_1 (\varepsilon_{t-1}^2 - \sigma^2) + \beta_1 (\sigma_{t-1}^2 - \sigma^2)$$

GARCH 모형의 예측:

- 스텝 $t + 1$ 의 예측은 다음과 같다.

$$\begin{aligned}\hat{\sigma}_{t+1}^2 - \sigma^2 &= \alpha_1 (\varepsilon_t^2 - \sigma^2) + \beta_1 (\sigma_t^2 - \sigma^2) \\ \Rightarrow \hat{\sigma}_{t+1}^2 &= \sigma^2 + \alpha_1 (\varepsilon_t^2 - \sigma^2) + \beta_1 (\sigma_t^2 - \sigma^2)\end{aligned}$$

- 다음 스텝 $t + 2$ 의 예측은 다음과 같다.

$$\begin{aligned}\hat{\sigma}_{t+2}^2 - \sigma^2 &= (\alpha_1 + \beta_1) (\hat{\sigma}_{t+1}^2 - \sigma^2) \\ \Rightarrow \hat{\sigma}_{t+2}^2 &= \sigma^2 + (\alpha_1 + \beta_1) (\hat{\sigma}_{t+1}^2 - \sigma^2)\end{aligned}$$

GARCH 모형의 예측:

- 한 스텝씩 미래의 예측값을 구해나가면 h 스텝에서는 다음과 같은 예측이 가능하다.

$$\hat{\sigma}_{t+h}^2 = \sigma^2 + (\alpha_1 + \beta_1)^{h-1} (\hat{\sigma}_{t+1}^2 - \sigma^2)$$

← 그대로 임

→ $0 < \alpha_1 + \beta_1 < 1$ 와 같은 제약조건이 충족된다면 $(\alpha_1 + \beta_1)^{h-1} \rightarrow 0$ 으로 수렴한다.

→ 그러면 $\hat{\sigma}_{t+h}^2 \rightarrow \sigma^2$ 와 같이 수렴함을 쉽게 확인할 수 있다.

문의:

sychang1@gmail.com